

Harness Engineering 기반 기업 공시문서 검토 Agent의 비용-신뢰도 효과 분석

부제

소형 LLM과 Harness Engineering 조합이 고성능 LLM을 대체할 수 있는가?

1. 연구 배경

최근 GPT-4, Claude, Gemini 등 대규모 언어모델(LLM)의 성능이 빠르게 발전하면서 기업 업무에 AI를 적용하려는 시도가 증가하고 있다.

그러나 실제 기업 환경에서는 단순한 모델 성능보다 다음과 같은 문제가 더 중요하다.

- 결과를 신뢰할 수 있는가?
- 왜 그런 결론을 내렸는지 설명 가능한가?
- 환각(Hallucination)을 통제할 수 있는가?
- 비용 대비 효과가 있는가?

특히 기업 문서 검토 업무는 수백 페이지에 달하는 사업보고서, 감사보고서, 공시문서를 분석해야 하며, 잘못된 판단은 투자 실패, 리스크 관리 실패, 규제 위반 등의 문제로 이어질 수 있다.

따라서 본 연구는 단순히 더 큰 모델을 사용하는 것이 아니라, Harness Engineering을 통해 더 작은 모델의 신뢰도를 향상시켜 실제 기업 업무에 활용 가능한 수준으로 만들 수 있는지를 검증하고자 한다.

2. 연구 문제

Research Question 1

Harness Engineering은 기업 문서 검토 업무에서 LLM의 신뢰도를 향상시키는가?

Research Question 2

소형 LLM + Harness 조합은 대형 LLM 단독 사용을 어느 정도 대체할 수 있는가?

Research Question 3

Harness 적용 시 비용 대비 성능(Cost-Reliability Tradeoff)은 얼마나 개선되는가?

3. 연구 대상 업무

기업 공시문서 리스크 검토 업무

실제 수행 주체

- 증권사 애널리스트
- VC 투자심사역
- PE 투자심사역
- 회계법인
- 기업 내부감사팀
- 리스크관리 부서

실제 업무

- 사업보고서 검토
 - 감사보고서 검토
 - 정정공시 검토
 - 기업 리스크 식별
 - 리스크 근거 확보
-

4. 데이터셋 구축

데이터 출처

DART(OpenDART)

수집 문서

- 사업보고서
 - 감사보고서
 - 정정공시
-

표본 규모

예시

상장기업 200~500개

기업당

- 사업보고서
- 감사보고서

수집

Ground Truth

방법 1

감사보고서 내 Key Audit Matter

방법 2

계속기업 불확실성 문구

방법 3

강조사항 문단

방법 4

감사의견 유형

- 적정
- 한정
- 부적정
- 의견거절

최종 Ground Truth

문서 내 실제 존재하는 리스크 항목

예

- 계속기업 리스크
- 유동성 리스크
- 내부통제 리스크
- 소송 리스크
- 재무건전성 리스크

5. Harness 설계

Baseline

Group A

LLM Only

입력

사업보고서

출력

리스크 목록

Harness 1

Group B

Retrieval-Augmented Analysis

추가 기능

- 문서 검색
 - 근거 문장 추출
-

Harness 2

Group C

Evidence Validation

추가 기능

- 모든 주장에 근거 요구
 - 근거 미존재 시 제거
-

Harness 3

Group D

Cross-document Validation

추가 기능

사업보고서

VS

감사보고서

VS

정정공시

비교

Harness 4

Group E

Self-Correction Loop

추가 기능

- 근거 부족 시 재분석
- 문서 재탐색

6. 실험군 구성

Group A

소형 모델 단독

예

GPT-4o-mini

Group B

소형 모델 + Harness

GPT-4o-mini

+

Retrieval

+

Validation

+

Cross-check

+

Self-Correction

Group C

대형 모델 단독

GPT-5급 모델

핵심 비교

Group B vs Group C

7. 평가 지표

Accuracy

실제 리스크 식별 정확도

Recall

실제 리스크 중 발견 비율

Precision

발견 리스크 중 정답 비율

Evidence Precision

제시된 근거의 정확도

Hallucination Rate

근거 없는 주장 비율

Reliability

동일 문서 반복 실행 시 결과 일관성

Cost

토큰 비용

API 비용

8. 핵심 가설

H1

Harness 적용 시 Precision이 향상된다.

H2

Harness 적용 시 Hallucination Rate가 감소한다.

H3

소형 모델 + Harness는 대형 모델 단독과 유사한 성능을 달성한다.

H4

소형 모델 + Harness가 비용 대비 효율 측면에서 가장 우수하다.

9. 기대 효과

경영학적 기여

AI를 단순 모델이 아닌 기업 운영 자산으로 활용하는 방안을 제시

기업 문서 검토 업무 자동화 가능성 검증

AI Governance 및 Risk Management 관점의 시사점 제공

데이터사이언스 기여

Harness Engineering의 효과 정량 검증

LLM 성능 향상보다 운영 아키텍처의 중요성 제시

비용-신뢰도 최적화 전략 제안

10. 연구 의의

본 연구는 더 강력한 모델 개발이 아닌, Harness Engineering을 활용하여 기업 업무에서 AI의 신뢰성과 경제성을 동시에 향상시킬 수 있는지를 검증한다.

이를 통해 기업 AI 도입의 핵심 과제가 모델 성능 경쟁이 아니라 운영 아키텍처 설계임을 실증적으로 제시하고자 한다.